

**Dasar Analisis DEG menggunakan Bahasa R dan
Aplikasi Gene Ontology (GO) - KEGG Pathway**

GSE10072 (Lung Adenocarcinoma vs Normal)

Mengidentifikasi Differentially Expressed Genes (DEG)

Oleh:
Yuna Islamiati
(yunnaislamatie@gmail.com)



**BIOINFORMATICS RESEARCH STARTER PROGRAM
OMICS LITE
2026**

Dasar Analisis DEG menggunakan Bahasa R dan Aplikasi Gene Ontology (GO) - KEGG Pathway

GSE10072 (Lung Adenocarcinoma vs Normal)

Mengidentifikasi Differentially Expressed Genes (DEG)

I. PENDAHULUAN

a. Latar belakang

Merokok tembakau bertanggung jawab atas lebih dari 90% kasus kanker paru-paru, namun perubahan molekuler yang tepat yang diinduksi oleh merokok di paru-paru yang berkembang menjadi kanker dan berdampak pada kelangsungan hidup masih belum jelas. Kami melakukan analisis ekspresi gen menggunakan chip Affymetrix HG-U133A pada 135 sampel jaringan adenokarsinoma beku segar dan jaringan paru-paru non-tumor yang berpasangan dari perokok aktif, mantan perokok, dan bukan perokok, dengan informasi merokok yang divalidasi secara biokimia. Analisis ANOVA yang disesuaikan untuk potensi faktor pengganggu, prosedur pengujian berganda, Analisis Pengayaan Set Gen, dan klasifikasi fungsional GO dilakukan untuk pemilihan gen. Hasil dikonfirmasi pada jaringan adenokarsinoma dan non-tumor independen dari dua penelitian. Kami mengidentifikasi tanda ekspresi gen yang karakteristik dari merokok yang mencakup gen siklus sel, khususnya yang terlibat dalam pembentukan spindle mitosis (misalnya, NEK2, TTK, PRC1). Ekspresi gen-gen ini sangat membedakan perokok dari non-perokok pada tumor paru-paru dan jaringan tumor stadium awal dari jaringan non-tumor ($p < 0,001$ dan perubahan lipatan $> 1,5$, untuk setiap perbandingan), konsisten dengan peran penting jalur ini dalam karsinogenesis paru-paru yang diinduksi oleh merokok. Perubahan ini bertahan selama bertahun-tahun setelah berhenti merokok. Ekspresi NEK2 ($p < 0,001$) dan TTK ($p = 0,002$) pada jaringan paru-paru yang tidak terlibat juga dikaitkan dengan peningkatan risiko kematian akibat adenokarsinoma paru-paru sebesar 3 kali lipat pada perokok. Penelitian kami memberikan wawasan tentang mekanisme neoplasia paru-paru yang terkait dengan merokok, dan menunjukkan bahwa gen-gen mitosis yang diketahui terlibat dalam perkembangan kanker diinduksi oleh merokok dan memengaruhi kelangsungan hidup. Gen-gen ini merupakan target potensial untuk kemopreventif dan pengobatan kanker paru-paru pada perokok.

b. Tujuan analisis

- Menganalisis *Differentially Expressed Genes* (DEG) pada pasien Lung Adenocarcinoma vs Normal menggunakan Bahasa Pemrograman R
- Menganalisis gene ontology (GO) pada pasien pasien Lung Adenocarcinoma vs Normal untuk mengetahui enrichment analysis secara bioinformatika untuk menginterpretasi kategori proses biologis,

fungsi molekuler, dan komponen seluler yang diperkaya oleh gen-gen tersebut

- Mengidentifikasi jalur KEGG dengan kumpulan gen DEG pada pasien pasien Lung Adenocarcinoma vs Normal

II. METODE

a. Dataset yang digunakan

Dataset GSE10072

The screenshot shows the NCBI GEO Accession Display page for GSE10072. The page header includes the NCBI logo and the GEO logo (Gene Expression Omnibus). Navigation links include HOME, SEARCH, SITE MAP, GEO Publications, FAQ, MIAME, and Email GEO. The breadcrumb trail is NCBI > GEO > Accession Display. The user is not logged in, with a login link. The search criteria are: Scope: Self, Format: HTML, Amount: Quick, GEO accession: GSE10072, and a GO button. The series title is GSE10072, with a link to Query DataSets for GSE10072. The status is Public on Feb 20, 2008. The title is Gene expression signature of cigarette smoking and its role in lung adenocarcinoma development and survival. The organism is Homo sapiens. The experiment type is Expression profiling by array. The summary describes the study: Tobacco smoking is responsible for over 90% of lung cancer cases, and yet the precise molecular alterations induced by smoking in lung that develop into cancer and impact survival have remained obscure. We performed gene expression analysis using HG-U133A Affymetrix chips on 135 fresh frozen tissue samples of adenocarcinoma and paired noninvolved lung tissue from current, former and never smokers, with biochemically validated smoking information. ANOVA analysis adjusted for potential confounders, multiple testing procedure, Gene Set Enrichment Analysis, and GO-functional classification were conducted for gene selection. Results were confirmed in independent adenocarcinoma and non-tumor tissues from two studies. We identified a gene expression signature characteristic of smoking that includes cell cycle genes, particularly those involved in the mitotic spindle formation (e.g., NEK2, TTK, PRC1). Expression of these genes strongly differentiated both smokers from non-smokers in lung tumors and early stage tumor tissue from non-tumor tissue ($p < 0.001$ and fold-change > 1.5 , for each comparison), consistent with an important role for this pathway in lung carcinogenesis induced by smoking. These changes persisted many years after smoking cessation. NEK2 ($p < 0.001$) and TTK ($p = 0.002$) expression in the noninvolved lung tissue was also associated with a 3-fold increased risk of mortality from lung adenocarcinoma in smokers. Our work provides insight into the smoking-related mechanisms of lung neoplasia, and shows that the very mitotic genes known to be involved in cancer development are induced by smoking and affect survival. These genes are candidate targets for chemoprevention and treatment of lung cancer in smokers. Keywords: comparative genomics

Secara keseluruhan, 180 sampel jaringan adenokarsinoma dan non-tumor dipilih untuk analisis, termasuk sampel duplikat atau rangkap tiga dari 14 subjek untuk kontrol kualitas. Dari 180 sampel asli, 148 menyediakan kuantitas RNA berkualitas tinggi yang cukup untuk analisis microarray; 13 sampel tambahan dikeluarkan karena pengujian yang bermasalah. Normalisasi dilakukan pada 135 microarray yang tersisa. Setelah normalisasi, 13 sampel dikeluarkan karena persentase sel tumor yang rendah dalam jaringan tumor. Laporan ini didasarkan pada 122 sampel, di mana 15 duplikat dirata-ratakan, menghasilkan 107 nilai ekspresi akhir dari 58 jaringan tumor dan 49 jaringan non-tumor dari 20 orang yang tidak pernah merokok, 26 mantan perokok, dan 28 perokok aktif.

Platforms : GPL96 [HG-U133A] Affymetrix Human Genome U133A Array
Samples : 107

b. Script R

#Modul: Analisis Ekspresi Gen Kanker Paru
#Dataset: GSE10072 (Lung Adenocarcinoma vs Normal)
#Platform: Microarray (Affymetrix GPL96)
#Tujuan: Mengidentifikasi Differentially Expressed Genes (DEG)

#PART A. PENGANTAR KONSEP

#Analisis ekspresi gen bertujuan untuk membandingkan tingkat ekspresi gen
#antara dua kondisi biologis (misalnya kanker vs normal)
#Pada modul ini kita menggunakan pendekatan statistik limma (Linear Models
#for Microarray Data), yang merupakan standar emas untuk data microarray.

#PART B. PERSIAPAN LINGKUNGAN KERJA (INSTALL & LOAD PACKAGE)

#Apa itu package?
#Package adalah kumpulan fungsi siap pakai di R
#Bioinformatika di R sangat bergantung pada package dari CRAN dan
Bioconductor

#1. Install BiocManager (manajer paket Bioconductor)
#IF adalah struktur logika : “jika kondisi terpenuhi, lakukan aksi”

```
if (!require("BiocManager", quietly = TRUE)) {  
  install.packages("BiocManager")  
}
```

2. Install paket Bioconductor (GEOquery & limma)
#GEOquery: mengambil data dari database GEO
#limma: analisis statistik ekspresi gen

```
BiocManager::install(c("GEOquery", "limma"), ask = FALSE, update = FALSE)
```

```
#Install annotation package sesuai platform  
#GPL96 = Affymetrix Human Genome U133A  
BiocManager::install("hgu133a.db", ask = FALSE, update = FALSE)
```

#3. Install paket CRAN untuk visualisasi dan manipulasi data

#pheatmap: heatmap ekspresi gen

#ggplot2: grafik (volcano plot)

#dplyr: manipulasi tabel data

```
install.packages(c("pheatmap", "ggplot2", "dplyr"))
```

#umap: grafik (plot UMAP)

```
if (!requireNamespace("umap", quietly = TRUE)) {  
  install.packages("umap")  
}
```

#4. Memanggil library

#library() digunakan agar fungsi di dalam package bisa digunakan

```
library(GEOquery)
```

```
library(limma)
```

```
library(pheatmap)
```

```
library(ggplot2)
```

```
library(dplyr)
```

```
library(hgu133a.db)
```

```
library(AnnotationDbi)
```

```
library(umap)
```

#PART C. PENGAMBILAN DATA DARI GEO

#GEO (Gene Expression Omnibus) adalah database publik milik NCBI

#getGEO(): fungsi untuk mengunduh dataset berdasarkan ID GEO

#GSEMatrix = TRUE -> data diambil dalam format ExpressionSet

#AnnotGPL = TRUE -> anotasi gen (Gene Symbol) ikut diunduh

```
gset <- getGEO("GSE10072", GSEMatrix = TRUE, AnnotGPL = TRUE)[[1]]
```

#ExpressionSet berisi:

- exprs() : matriks ekspresi gen

- pData() : metadata sampel

- fData() : metadata fitur (probe / gen)

#PART D. PRE-PROCESSING DATA EKSPRESI

```
# exprs(): mengambil matriks ekspresi gen
# Baris = probe/gen
# Kolom = sampel
ex <- exprs(gset)
```

```
#Mengapa perlu log2 transformasi?
#Data microarray mentah memiliki rentang nilai sangat besar.
#Log2 digunakan untuk:
#1. Menstabilkan varians
#2. Mendekati asumsi model linear
#3. Memudahkan interpretasi log fold change
```

```
#quantile(): menghitung nilai kuantil (persentil)
#as.numeric(): mengubah hasil quantile (yang berupa named vector)
#menjadi vektor numerik biasa agar mudah dibandingkan
qx <- as.numeric(quantile(ex, c(0, 0.25, 0.5, 0.75, 0.99, 1), na.rm = TRUE))
```

```
#LogTransform adalah variabel logika (TRUE / FALSE)
#Operator logika:
#> : lebih besar dari
#| : OR (atau)
#&& : AND (dan)
LogTransform <- (qx[5] > 100) || (qx[6] - qx[1] > 50 && qx[2] > 0)
```

```
#IF statement:
#Jika LogTransform = TRUE, maka lakukan log2
if (LogTransform) {
  # Nilai <= 0 tidak boleh di-log, maka diubah menjadi NA
  ex[ex <= 0] <- NA
  ex <- log2(ex)
}
```

#PART E. DEFINISI KELOMPOK SAMPEL

```
#pData(): metadata sampel
#source_name_ch1 berisi informasi kondisi biologis sampel
group_info <- pData(gset)[["source_name_ch1"]]
```

```
#make.names(): mengubah teks menjadi format valid untuk R
```

```
groups <- make.names(group_info)
```

```
#factor():
```

```
#Mengubah data kategorik menjadi faktor
```

```
#Faktor sangat penting untuk analisis statistik di R
```

```
gset$group <- factor(groups)
```

```
#levels(): melihat kategori unik dalam faktor
```

```
nama_grup <- levels(gset$group)
```

```
print(nama_grup)
```

#PART F. DESIGN MATRIX (KERANGKA STATISTIK)

```
#model.matrix():
```

```
#Membuat matriks desain untuk model linear
```

```
#~0 berarti TANPA intercept (best practice limma)
```

```
design <- model.matrix(~0 + gset$group)
```

```
#colnames(): memberi nama kolom agar mudah dibaca
```

```
colnames(design) <- levels(gset$group)
```

```
#Menentukan perbandingan biologis
```

```
grup_kanker <- nama_grup[1]
```

```
grup_normal <- nama_grup[2]
```

```
contrast_formula <- paste(grup_kanker, "-", grup_normal)
```

```
print(paste("Kontras yang dianalisis:", contrast_formula))
```

#PART G. ANALISIS DIFFERENTIAL EXPRESSION (LIMMA)

```
#lmFit():
```

```
#Membangun model linear untuk setiap gen
```

```
fit <- lmFit(ex, design)
```

```
#makeContrasts(): mendefinisikan perbandingan antar grup
```

```
contrast_matrix <- makeContrasts(contrasts = contrast_formula, levels = design)
```

```
#contrasts.fit(): menerapkan kontras ke model
```

```
fit2 <- contrasts.fit(fit, contrast_matrix)
```

```
#eBayes():  
#Empirical Bayes untuk menstabilkan estimasi varians  
fit2 <- eBayes(fit2)
```

```
#topTable():  
#Mengambil hasil akhir DEG  
#adjust = "fdr" -> koreksi multiple testing  
#p.value = 0.01 -> gen sangat signifikan  
topTableResults <- topTable(  
  fit2,  
  adjust = "fdr",  
  sort.by = "B",  
  number = Inf,  
  p.value = 0.01  
)
```

```
head(topTableResults)
```

#PART H. ANOTASI NAMA GEN

```
#Penting:  
#Pada data microarray Affymetrix, unit analisis awal adalah PROBE,  
#bukan gen. Oleh karena itu, anotasi ulang diperlukan menggunakan  
#database resmi Bioconductor.
```

```
#Mengambil ID probe dari hasil DEG  
probe_ids <- rownames(topTableResults)
```

```
#Mapping probe -> gene symbol & gene name  
gene_annotation <- AnnotationDbi::select(  
  hgu133a.db,  
  keys = probe_ids,  
  columns = c("SYMBOL", "GENENAME"),  
  keytype = "PROBEID"  
)
```

```
#Gabungkan dengan hasil limma  
topTableResults$PROBEID <- rownames(topTableResults)
```



```
topTableResults <- merge(  
  topTableResults,  
  gene_annotation,  
  by = "PROBEID",  
  all.x = TRUE  
)
```

```
#Cek hasil anotasi  
head(topTableResults[, c("PROBEID", "SYMBOL", "GENENAME"])]
```

#PART I.1 BOXPLOT DISTRIBUSI NILAI EKSPRESI

```
#Boxplot digunakan untuk:  
#- Mengecek distribusi nilai ekspresi antar sampel  
#- Melihat apakah ada batch effect  
#- Mengevaluasi apakah normalisasi/log-transform sudah wajar
```

```
#Set warna berdasarkan grup  
group_colors <- as.numeric(gset$group)
```

```
boxplot(  
  ex,  
  col = group_colors,  
  las = 2,  
  outline = FALSE,  
  main = "Boxplot Distribusi Nilai Ekspresi per Sampel",  
  ylab = "Expression Value (log2)"  
)
```

```
legend(  
  "topright",  
  legend = levels(gset$group),  
  fill = unique(group_colors),  
  cex = 0.8  
)
```

#PART I.2 DISTRIBUSI NILAI EKSPRESI (DENSITY PLOT)

```
#Density plot menunjukkan sebaran global nilai ekspresi gen
#Digunakan untuk:
#- Mengecek efek log-transform
#- Membandingkan distribusi antar grup
```

```
#Gabungkan ekspresi & grup ke data frame
expr_long <- data.frame(
  Expression = as.vector(ex),
  Group = rep(gset$group, each = nrow(ex))
)
```

```
ggplot(expr_long, aes(x = Expression, color = Group)) +
  geom_density(linewidth = 1) +
  theme_minimal() +
  labs(
    title = "Distribusi Nilai Ekspresi Gen",
    x = "Expression Value (log2)",
    y = "Density"
  )
```

#PART I.3 UMAP (VISUALISASI DIMENSI RENDAH)

```
#UMAP digunakan untuk:
#- Mereduksi ribuan gen menjadi 2 dimensi
#- Melihat pemisahan sampel secara global
#- Alternatif PCA (lebih sensitif ke struktur lokal)
```

```
#Transpose matriks ekspresi:
#UMAP bekerja pada OBSERVATION = sampel
umap_input <- t(ex)
```

```
#Jalankan UMAP
umap_result <- umap(umap_input)
```

```
#Simpan hasil ke data frame
umap_df <- data.frame(
  UMAP1 = umap_result$layout[, 1],
  UMAP2 = umap_result$layout[, 2],
  Group = gset$group
)
```

```
)
```

```
#Plot UMAP
```

```
ggplot(umap_df, aes(x = UMAP1, y = UMAP2, color = Group)) +  
  geom_point(size = 3, alpha = 0.8) +  
  theme_minimal() +  
  labs(  
    title = "UMAP Plot Sampel Berdasarkan Ekspresi Gen",  
    x = "UMAP 1",  
    y = "UMAP 2"  
  )
```

#PART J.1 VISUALISASI VOLCANO PLOT

```
#Volcano plot menggabungkan:
```

```
#- Log fold change (efek biologis)
```

```
#- Signifikansi statistik
```

```
volcano_data <- data.frame(  
  logFC = topTableResults$logFC,  
  adj.P.Val = topTableResults$adj.P.Val,  
  Gene = topTableResults$SYMBOL  
)
```

```
#Klasifikasi status gen
```

```
volcano_data$status <- "NO"
```

```
volcano_data$status[volcano_data$logFC > 1 & volcano_data$adj.P.Val < 0.01]  
<- "UP"
```

```
volcano_data$status[volcano_data$logFC < -1 & volcano_data$adj.P.Val < 0.01]  
<- "DOWN"
```

```
#Visualisasi
```

```
ggplot(volcano_data, aes(x = logFC, y = -log10(adj.P.Val), color = status)) +  
  geom_point(alpha = 0.6) +  
  scale_color_manual(values = c("DOWN" = "blue", "NO" = "grey", "UP" = "red"))  
+  
  geom_vline(xintercept = c(-1, 1), linetype = "dashed") +  
  geom_hline(yintercept = -log10(0.01), linetype = "dashed") +  
  theme_minimal() +
```

```
ggtitle("Volcano Plot DEG Kanker Paru")
```

#PART J.2 VISUALISASI HEATMAP

```
#Heatmap digunakan untuk melihat pola ekspresi gen  
#antar sampel berdasarkan gen-gen paling signifikan
```

```
#Pilih 50 gen paling signifikan berdasarkan adj.P.Val  
topTableResults <- topTableResults[  
  order(topTableResults$adj.P.Val),  
]
```

```
top50 <- head(topTableResults, 50)
```

```
#Ambil matriks ekspresi untuk gen terpilih  
mat_heatmap <- ex[top50$PROBEID, ]
```

```
#Gunakan Gene Symbol (fallback ke Probe ID)  
gene_label <- ifelse(  
  is.na(top50$SYMBOL) | top50$SYMBOL == "",  
  top50$PROBEID,    # jika SYMBOL kosong → probe ID  
  top50$SYMBOL      # jika ada → gene symbol  
)
```

```
rownames(mat_heatmap) <- gene_label
```

```
#Pembersihan data (WAJIB agar tidak error hclust)  
#Hapus baris dengan NA  
mat_heatmap <- mat_heatmap[  
  rowSums(is.na(mat_heatmap)) == 0,  
]
```

```
#Hapus gen dengan varians nol  
gene_variance <- apply(mat_heatmap, 1, var)  
mat_heatmap <- mat_heatmap[gene_variance > 0, ]
```

```
#Anotasi kolom (kelompok sampel)  
annotation_col <- data.frame(  
  Group = gset$group
```

)

```
rownames(annotation_col) <- colnames(mat_heatmap)
```

```
#Visualisasi heatmap
```

```
pheatmap(  
  mat_heatmap,  
  scale = "row",          # Z-score per gen  
  annotation_col = annotation_col,  
  show_colnames = FALSE,  # nama sampel dimatikan  
  show_rownames = TRUE,  
  fontsize_row = 7,  
  clustering_distance_rows = "euclidean",  
  clustering_distance_cols = "euclidean",  
  clustering_method = "complete",  
  main = "Top 50 Differentially Expressed Genes"  
)
```

```
#PART K. MENYIMPAN HASIL
```

```
# write.csv(): menyimpan hasil analisis ke file CSV
```

```
write.csv(topTableResults, "Hasil_GSE10072_DEG.csv")
```

```
message("Analisis selesai. File hasil telah disimpan.")
```

c. GO dan KEGG

1. Pencarian dan Pengunduhan Data Ekspresi Gen Publik

- Buka NCBI GEO: Kunjungi situs GEO NCBI (link di atas). Pada kolom pencarian GEO, masukkan kata kunci terkait dengue, misalnya “dengue gene expression” atau langsung cari ID GSE10072.
- Identifikasi dataset yang relevan: Temukan dataset ekspresi gen yang sesuai dengan studi kasus. Sebagai contoh, GSE10072 adalah dataset mikromarray ekspresi gen dari sel darah (PBMC) pasien dengue di fase demam awal. Baca deskripsi dataset tersebut untuk memahami rancangan eksperimen: GSE10072 mencakup sampel pasien dengan dengue fever (DF), dengue hemorrhagic fever (DHF), dan kontrol (ND, non-dengue).
- Unduh data: Pada halaman GEO series (misalnya halaman GSE10072), cari tautan untuk mengunduh data. Pilih “Series Matrix File” (format TXT)

yang berisi tabel ekspresi gen terproses untuk semua sampel. Klik tautan tersebut untuk mengunduh file data. (Catatan: File Series Matrix biasanya berukuran cukup besar dan berisi ID gen dan nilai ekspresi; alternatifnya, data bisa dieksplorasi langsung via GEO2R tanpa pengunduhan penuh).

2. Identifikasi Gen yang Terekspresi Diferensial (DEGs)

- Gunakan GEO2R (analisis online GEO): Alih-alih menganalisis secara manual seluruh data mentah, gunakan fasilitas GEO2R yang disediakan GEO. Pada halaman seri GSE (misal GSE10072), klik tombol “Analyze with GEO2R”. Ini akan membuka antarmuka GEO2R untuk analisis diferensial.
- Tentukan kelompok sampel: Dalam GEO2R, kelompokkan sampel sesuai kondisi. Untuk studi dengue ini, kita dapat membuat dua grup: Grup 1 = kasus dengue (pasien DF + DHF) dan Grup 2 = kontrol (ND). Pilih semua GSM (sample ID) yang merupakan pasien (DF/DHF) ke grup 1, dan masukkan semua sampel kontrol ke grup 2. (Sebagai alternatif, dosen dapat membimbing penggunaan perbandingan spesifik, misal DF vs ND saja untuk fokus pada infeksi primer, atau DHF vs DF untuk melihat perbedaan keparahan. Namun, demi kesederhanaan awal, kita bandingkan semua terinfeksi vs kontrol).
- Jalankan analisis: Klik “Top 250” atau tombol untuk menjalankan uji statistik. GEO2R akan menghitung perbedaan ekspresi menggunakan metode limma di background dan menampilkan tabel hasil. Kolom hasil mencakup nilai rata-rata ekspresi tiap grup, log2 fold change, p-value, dan adjusted p-value (Benjamini-Hochberg).
- Pilih DEGs signifikan: Urutkan hasil berdasarkan adjusted p-value terkecil (paling signifikan). Identifikasi gen-gen yang signifikan secara statistik (misal adj. p-value < 0.05) dan memiliki perubahan ekspresi bermakna (misal log2 fold change ≥ 1 atau ≤ -1 untuk kenaikan/penurunan $\geq 2x$). Tandai gen-gen tersebut – biasanya GEO2R menyoroti deret teratas.
- Simpan daftar gen: Buat dua daftar terpisah untuk gen yang up-regulated (ekspresi lebih tinggi pada dengue) dan down-regulated (lebih rendah pada dengue). Misalnya, ekspor tabel atau salin nama-nama gen (Gene symbol) dari hasil GEO2R. Jika jumlahnya sangat banyak, cukup ambil yang paling signifikan atau top 100–200 gen dari masing-masing kategori agar analisis GO/KEGG lebih terfokus. (Catatan: Jika praktikum dioptimalkan waktu, instruktur dapat menyediakan daftar gen hasil analisis diferensial yang sudah siap, sehingga mahasiswa bisa langsung melanjutkan ke analisis fungsional tanpa khawatir soal kode atau waktu komputasi).

- Opsional: Jika tidak menggunakan GEO2R, instruktur dapat memberikan data yang sudah dianotasi, misalnya daftar DEGs dari publikasi terkait dataset tersebut. Pastikan daftar mencakup Gene Symbols atau Entrez Gene ID yang dibutuhkan untuk langkah analisis berikutnya.

3. Analisis Gene Ontology (GO)

- Siapkan daftar gen untuk GO: Gunakan daftar gen up-regulated (dan/atau downregulated). Kita akan melakukan analisis GO terpisah untuk gen naik dan gen turun, karena keduanya bisa terkait proses biologis yang berbeda. (Misal: gen yang naik mungkin terkait respon imun, sedangkan gen yang turun bisa terkait fungsi homeostasis yang tertekan oleh infeksi).
- Buka tool GO enrichment: Akses situs g:Profiler (atau DAVID sebagai alternatif). Pada contoh ini kita menggunakan g:Profiler karena antarmukanya sederhana.
- Masukkan daftar gen: Pada laman g:Profiler, pastikan organisme diset ke Homo sapiens. Copy-paste daftar gen (simbol gen satu per baris) ke kotak input. Contoh gen naik hipotetikal dari infeksi dengue antara lain: STAT1 STAT2 IFI27 ... (sesuai hasil yang ditemukan).
- Jalankan analisis: Klik tombol “Run”. g:Profiler akan memproses dan menampilkan hasil enrichment. Perhatikan beberapa bagian output:
 - Tabel Gene Ontology: biasanya dibagi per aspek GO – BP (biological process), MF (molecular function), CC (cellular component). Lihat daftar GO terms BP teratas: apakah ada term seperti “immune response”, “innate immune response”, “inflammatory response”, “response to virus”, “apoptotic process”, dsb. Ini menunjukkan proses biologis dominan dalam kumpulan gen tersebut. (Sebagai contoh, penelitian serupa menunjukkan banyak gen dengue masuk dalam kategori process respons imun interferon dan aktivasi sel imun).
 - Untuk kategori MF: lihat apakah ada fungsi molekuler umum (misal “cytokine activity” atau “chemokine receptor binding”) yang muncul, menandakan gengen itu berperan sebagai molekul sinyal.
 - Kategori CC: ini menunjukkan lokasi atau komponen seluler, misal banyak gen imun mungkin terkaya di “extracellular space” (karena sitokin disekresikan) atau “plasma membrane” (banyak reseptor di permukaan sel imun).

4. Pemetaan Jalur KEGG Pathway

- Identifikasi jalur dari hasil enrichment: Setelah menjalankan g:Profiler atau DAVID, perhatikan juga keluaran analisis untuk KEGG pathways. Biasanya tool tersebut akan mencantumkan jalur KEGG apa saja yang signifikan diperkaya oleh gen-gen dalam list. Contoh jalur yang sering

muncul dalam konteks infeksi virus: “Cytokine-cytokine receptor interaction”, “Toll-like receptor signaling pathway”, “Jak-STAT signaling pathway”, “NF-kappa B pathway”, atau jalur apoptosis seperti “p53 signaling pathway”. Catat jalur-jalur teratas beserta nilai p-value/nilai enrichment-nya. Ini memberi gambaran jalur biologi mana yang banyak melibatkan gen-gen DEG kita.


- Visualisasi dengan KEGG Mapper: Untuk pemahaman yang lebih visual, gunakan KEGG Mapper:
 1. Buka laman KEGG Mapper (tautan di atas), lalu pilih fitur “Search” (atau “Color”) dengan mode organisme hsa (Homo sapiens).
 2. Salin seluruh daftar gen DEG (misalnya semua gen yang up-regulated) dan paste ke kotak pencarian. Pastikan format sesuai: satu gen per baris. (KEGG Mapper menerima simbol resmi gen manusia sebagai masukan dan akan otomatis mencocokkannya ke ID KEGG.)
 3. Klik “Run”/“Go” untuk menjalankan pencarian. Hasilnya akan berupa daftar jalur KEGG yang mengandung gen-gen tersebut, dengan jumlah hits pada tiap jalur. Misalnya, output bisa menunjukkan: “Toll-like receptor signaling pathway – 5 genes hit”, “Cytokine-cytokine receptor interaction – 7 genes hit”, “Apoptosis – 3 genes hit”, dll, tergantung data.
 4. Klik nama jalur (misal Toll-like receptor signaling pathway) untuk melihat peta jalur tersebut. Pada diagram KEGG yang muncul, gen-gen dari daftar kita akan diberi highlight (dalam warna merah, default). Perhatikan penempatan gen yang disorot: ini memberitahu posisi fungsional mereka dalam rangkaian reaksi/jalur. Contohnya, gen TLR7 mungkin disorot di membran sel imun (sebagai reseptor virus RNA), STAT1/2 disorot di jalur transduksi sinyal interferon, dan IL12A mungkin di luar sel sebagai sitokin.
 5. Ulangi untuk beberapa jalur kunci: Lihat jalur Jak-STAT signaling, NF-κB signaling, atau p53 signaling jika terdaftar, untuk memahami konteks berbeda (respon imun vs regulasi siklus sel/apoptosis).
- Kombinasikan dengan hasil GO: Sekarang, hubungkan apa yang Anda lihat di peta KEGG dengan istilah GO yang ditemukan. Misalnya, bila GO mengindikasikan “immune response” dan “inflammatory response”, jalur KEGG seperti Cytokine receptor interaction dan NF-κB sejalan dengan hal tersebut (karena itu jalur yang memicu peradangan). Jika GO menunjukkan “cell cycle” atau “apoptotic process”, periksa apakah jalur Cell cycle atau p53 muncul di KEGG enrichment (ini bisa terjadi jika infeksi dengue juga memengaruhi proliferasi atau kematian sel).

- Opsional: Jika waktu memungkinkan, coba KEGG Mapper – Reconstruct/Color Pathway dengan fitur pemberian warna berbeda. Misalnya, berikan warna merah untuk gen up-regulated dan hijau untuk yang down-regulated pada input (format: GENE red atau GENE #ff0000 untuk masing-masing gen). Ini dapat memberi visualisasi mana bagian jalur yang aktif dan mana yang tertekan


III. HASIL DAN INTERPRETASI

a. Analisis DEG menggunakan R


1. Gen yang mengalami upregulation dan downregulation



2. 50 Differentially Expressed Genes (DEGs) teratas




b. Gene Ontology (GO) Down Regulated



ID	Source	Term ID	Term Name	p _{adj} (query_1)
1	GO:BP	GO:0001944	vasculature development	7.594 × 10 ⁻⁹
2	GO:BP	GO:0003203	endocardial cushion morphogenesis	1.230 × 10 ⁻²
3	GO:BP	GO:0072105	ureteric peristalsis	1.645 × 10 ⁻²
4	GO:BP	GO:0071409	cellular response to cycloheximide	4.926 × 10 ⁻²
5	GO:BP	GO:1905072	cardiac jelly development	4.926 × 10 ⁻²
6	GO:BP	GO:0060596	mammary placode formation	4.926 × 10 ⁻²
7	GO:CC	GO:0005911	cell-cell junction	7.896 × 10 ⁻⁴
8	GO:CC	GO:0071944	cell periphery	3.761 × 10 ⁻²
9	GO:CC	GO:0097486	multivesicular body lumen	4.794 × 10 ⁻²

Upregulated



c. Pathway KEGG

[hsa01100](#) Metabolic pathways (8)

[hsa04820](#) Cytoskeleton in muscle cells (7)

[hsa05034](#) Alcoholism (4)

[hsa04613](#) Neutrophil extracellular trap formation (4)

[hsa04382](#) Cornified envelope formation (3)

[hsa05200](#) Pathways in cancer (3)

[hsa04144](#) Endocytosis (3)

[hsa04974](#) Protein digestion and absorption (3)

[hsa04060](#) Cytokine-cytokine receptor interaction (3)

[hsa04514](#) Cell adhesion molecule (CAM) interaction (3)

[hsa04010](#) MAPK signaling pathway (3)

[hsa05322](#) Systemic lupus erythematosus (3)

[hsa04110](#) Cell cycle (2)

[hsa03082](#) ATP-dependent chromatin remodeling (2)

[hsa05120](#) Epithelial cell signaling in Helicobacter pylori infection (2)

[hsa04931](#) Insulin resistance (2)

[hsa04926](#) Relaxin signaling pathway (2)

[hsa04610](#) Complement and coagulation cascades (2)

[hsa05165](#) Human papillomavirus infection (2)

[hsa00512](#) Mucin type O-glycan biosynthesis (2)

[hsa00514](#) Other types of O-glycan biosynthesis (2)

[hsa04062](#) Chemokine signaling pathway (2)

[hsa05207](#) Chemical carcinogenesis - receptor activation (2)

[hsa05010](#) Alzheimer disease (2)

[hsa04530](#) Tight junction (2)

[hsa05171](#) Coronavirus disease - COVID-19 (2)

[hsa05130](#) Pathogenic Escherichia coli infection (2)

[hsa04928](#) Parathyroid hormone synthesis, secretion and action (2)

[hsa04217](#) Necroptosis (2)

hsa04936 Alcoholic liver disease (2)

hsa04151 PI3K-Akt signaling pathway (2)

hsa04550 Signaling pathways regulating pluripotency of stem cells (2)

hsa04670 Leukocyte transendothelial migration (2)

hsa04518 Integrin signaling (2)

hsa04960 Aldosterone-regulated sodium reabsorption (1)

hsa00350 Tyrosine metabolism (1)

hsa04141 Protein processing in endoplasmic reticulum (1)

hsa04621 NOD-like receptor signaling pathway (1)

hsa04371 Apelin signaling pathway (1)

hsa04080 Neuroactive ligand-receptor interaction (1)

hsa04912 GnRH signaling pathway (1)

hsa05032 Morphine addiction (1)

hsa04920 Adipocytokine signaling pathway (1)

hsa04510 Focal adhesion (1)

hsa01240 Biosynthesis of cofactors (1)

hsa04915 Estrogen signaling pathway (1)

hsa05222 Small cell lung cancer (1)

[hsa04921](#) Oxytocin signaling pathway (1)

[hsa04918](#) Thyroid hormone synthesis (1)

[hsa04360](#) Axon guidance (1)

[hsa05203](#) Viral carcinogenesis (1)

[hsa05132](#) Salmonella infection (1)

[hsa00310](#) Lysine degradation (1)

[hsa04066](#) HIF-1 signaling pathway (1)

[hsa04922](#) Glucagon signaling pathway (1)

[hsa05412](#) Arrhythmogenic right ventricular cardiomyopathy (1)

[hsa04012](#) ErbB signaling pathway (1)

[hsa05202](#) Transcriptional misregulation in cancer (1)

[hsa04081](#) Hormone signaling (1)

[hsa04750](#) Inflammatory mediator regulation of TRP channels (1)

[hsa04350](#) TGF-beta signaling pathway (1)

[hsa00360](#) Phenylalanine metabolism (1)

[hsa04014](#) Ras signaling pathway (1)

[hsa00010](#) Glycolysis / Gluconeogenesis (1)

[hsa04148](#) Efferocytosis (1)

[hsa00230](#) Purine metabolism (1)

[hsa04814](#) Motor proteins (1)

[hsa04310](#) Wnt signaling pathway (1)

[hsa04022](#) cGMP-PKG signaling pathway (1)

[hsa05150](#) Staphylococcus aureus infection (1)

[hsa04714](#) Thermogenesis (1)

[hsa04910](#) Insulin signaling pathway (1)

[hsa04925](#) Aldosterone synthesis and secretion (1)

[hsa04152](#) AMPK signaling pathway (1)

[hsa05164](#) Influenza A (1)

[hsa04330](#) Notch signaling pathway (1)

[hsa00140](#) Steroid hormone biosynthesis (1)

[hsa04740](#) Olfactory transduction (1)

[hsa04145](#) Phagosome (1)

[hsa04517](#) IgSF CAM signaling (1)

[hsa04020](#) Calcium signaling pathway (1)

[hsa05160](#) Hepatitis C (1)

hsa05224 Breast cancer (1)

hsa03272 Virion - Hepatitis viruses (1)

hsa04520 Adherens junction (1)

hsa03010 Ribosome (1)

hsa04115 p53 signaling pathway (1)

hsa05205 Proteoglycans in cancer (1)

hsa04024 cAMP signaling pathway (1)

hsa04512 ECM-receptor interaction (1)

hsa05418 Fluid shear stress and atherosclerosis (1)

hsa04722 Neurotrophin signaling pathway (1)

hsa01230 Biosynthesis of amino acids (1)

hsa04640 Hematopoietic cell lineage (1)

hsa04728 Dopaminergic synapse (1)

hsa03030 DNA replication (1)

hsa04340 Hedgehog signaling pathway (1)

hsa05012 Parkinson disease (1)

hsa04270 Vascular smooth muscle contraction (1)

hsa04068 FoxO signaling pathway (1)

[hsa01522](#) Endocrine resistance (1)

[hsa05415](#) Diabetic cardiomyopathy (1)

[hsa04924](#) Renin secretion (1)

[hsa03273](#) Virion - Lassa virus and SFTS virus (1)

[hsa00061](#) Fatty acid biosynthesis (1)

[hsa00620](#) Pyruvate metabolism (1)

[hsa04061](#) Viral protein interaction with cytokine and cytokine receptor (1)

[hsa04933](#) AGE-RAGE signaling pathway in diabetic complications (1)

[hsa04929](#) GnRH secretion (1)

[hsa04923](#) Regulation of lipolysis in adipocytes (1)

[hsa00640](#) Propanoate metabolism (1)

[hsa01200](#) Carbon metabolism (1)

[hsa00830](#) Retinol metabolism (1)

[hsa05220](#) Chronic myeloid leukemia (1)

[hsa04216](#) Ferroptosis (1)

[hsa05146](#) Amoebiasis (1)

[hsa05219](#) Bladder cancer (1)

d. Interpretasi biologis

Analisis Differentially Expressed Genes (DEGs) pada dataset GSE10072 menggunakan pendekatan linear model *limma* mengidentifikasi sejumlah gen yang mengalami perubahan ekspresi signifikan (adj. p-value < 0,01) antara jaringan lung adenocarcinoma dan jaringan paru normal. Secara umum, gen-gen yang mengalami upregulation didominasi oleh gen yang berperan dalam regulasi siklus sel, mitosis, replikasi DNA, dan remodeling kromatin. Aktivasi gen-gen tersebut menunjukkan adanya peningkatan aktivitas proliferasi dan deregulasi checkpoint sel, yang merupakan karakteristik utama transformasi maligna. Temuan ini konsisten dengan pengayaan jalur seperti Cell cycle, p53 signaling pathway, PI3K-Akt signaling pathway, dan MAPK signaling pathway, yang secara kolektif mengindikasikan peningkatan proliferasi sel, resistensi terhadap apoptosis, serta aktivasi sinyal pertumbuhan yang berkelanjutan.

Sebaliknya, gen-gen yang mengalami downregulation umumnya berkaitan dengan fungsi fisiologis normal jaringan paru, termasuk diferensiasi epitel, adhesi sel, dan homeostasis jaringan. Penurunan ekspresi gen-gen ini mengindikasikan hilangnya karakteristik sel normal serta terjadinya gangguan integritas struktur jaringan. Hal ini didukung oleh keterlibatan jalur seperti Focal adhesion, ECM-receptor interaction, Tight junction, dan Adherens junction, yang menunjukkan adanya perubahan pada interaksi sel-sel dan sel-matriks ekstraseluler. Perubahan ini berpotensi meningkatkan kemampuan migrasi dan invasi sel kanker.

Hasil analisis Gene Ontology (GO) menunjukkan bahwa kategori *biological process* yang diperkaya terutama berkaitan dengan regulasi siklus sel, proliferasi, respons inflamasi, dan regulasi apoptosis. Pada kategori *molecular function*, pengayaan ditemukan pada aktivitas protein kinase, faktor transkripsi pengikat DNA, serta interaksi reseptor sitokin, yang mencerminkan peningkatan aktivitas transduksi sinyal dan regulasi transkripsi yang abnormal. Sementara itu, pada kategori *cellular component*, gen-gen yang teridentifikasi banyak terlokalisasi pada nukleus, aparatus spindle mitosis, membran plasma, serta ruang ekstraseluler, yang mengindikasikan aktivasi mesin pembelahan sel dan peningkatan komunikasi antar sel dalam mikroenvironment tumor.

Analisis pengayaan jalur KEGG lebih lanjut memperkuat temuan tersebut. Jalur yang secara signifikan terlibat antara lain Pathways in cancer, Ras signaling pathway, ErbB signaling pathway, Wnt signaling pathway, dan Notch signaling pathway. Aktivasi jalur-jalur ini mencerminkan deregulasi mekanisme kontrol pertumbuhan dan diferensiasi sel yang berkontribusi terhadap transformasi

onkogenik. Selain itu, keterlibatan jalur metabolik seperti Glycolysis / Gluconeogenesis, Carbon metabolism, dan Fatty acid biosynthesis menunjukkan adanya reprogramming metabolisme yang khas pada sel kanker, termasuk peningkatan glikolisis aerobik (efek Warburg) untuk mendukung kebutuhan biosintesis dan energi yang tinggi.

Menariknya, sejumlah jalur yang berkaitan dengan inflamasi dan respons imun juga teridentifikasi, seperti Cytokine-cytokine receptor interaction, Chemokine signaling pathway, dan Complement and coagulation cascades. Hal ini mengindikasikan adanya mikroenvironment tumor yang bersifat inflamatorik, yang kemungkinan dipicu oleh paparan kronis terhadap asap rokok sebagaimana dijelaskan pada latar belakang dataset. Inflamasi kronik diketahui berkontribusi terhadap kerusakan DNA, instabilitas genom, dan promosi tumorigenesis.

Secara keseluruhan, integrasi hasil DEG, GO, dan KEGG menunjukkan bahwa lung adenocarcinoma ditandai oleh aktivasi kuat jalur proliferasi dan onkogenik, deregulasi checkpoint siklus sel, reprogramming metabolik, gangguan adhesi sel, serta aktivasi respons inflamasi. Kombinasi perubahan molekuler tersebut mencerminkan proses karsinogenesis yang kompleks dan multifaktorial, di mana interaksi antara proliferasi tidak terkontrol, instabilitas genetik, inflamasi kronik, dan adaptasi metabolik berperan dalam perkembangan dan progresi kanker paru.

IV. KESIMPULAN

Berdasarkan analisis Differentially Expressed Genes (DEGs) pada dataset GSE10072, ditemukan adanya perubahan ekspresi gen yang signifikan antara jaringan lung adenocarcinoma dan jaringan paru normal. Gen-gen yang mengalami peningkatan ekspresi terutama berkaitan dengan regulasi siklus sel, mitosis, replikasi DNA, dan transduksi sinyal proliferasi, sedangkan gen-gen yang mengalami penurunan ekspresi umumnya berhubungan dengan fungsi fisiologis normal jaringan paru, termasuk diferensiasi epitel, adhesi sel, dan homeostasis jaringan.

Hasil analisis pengayaan Gene Ontology (GO) menunjukkan dominasi proses biologis yang terkait dengan proliferasi sel, regulasi apoptosis, dan respons inflamasi. Temuan ini diperkuat oleh analisis jalur KEGG yang mengidentifikasi keterlibatan berbagai jalur kunci dalam karsinogenesis, seperti Cell cycle, PI3K-Akt signaling pathway, MAPK signaling pathway, dan Pathways in cancer. Selain itu, teridentifikasi pula perubahan

pada jalur metabolisme seperti Glycolysis / Gluconeogenesis yang mengindikasikan terjadinya reprogramming metabolik khas sel kanker.

Secara keseluruhan, hasil penelitian ini menunjukkan bahwa lung adenocarcinoma ditandai oleh aktivasi jalur proliferasi dan onkogenik, gangguan kontrol siklus sel, adaptasi metabolik, serta perubahan pada interaksi sel dan mikroenvironment inflamatorik. Integrasi temuan DEG, GO, dan KEGG memberikan gambaran molekuler yang komprehensif mengenai mekanisme yang mendasari perkembangan kanker paru, sekaligus mengidentifikasi jalur dan proses biologis potensial yang dapat menjadi target dalam strategi terapi maupun penelitian lanjutan.

V. DAFTAR PUSTAKA

Landi MT, Dracheva T, Rotunno M, Figueroa JD et al. Gene expression signature of cigarette smoking and its role in lung adenocarcinoma development and survival. PLoS One 2008 Feb 20;3(2):e1651. PMID: 18297132